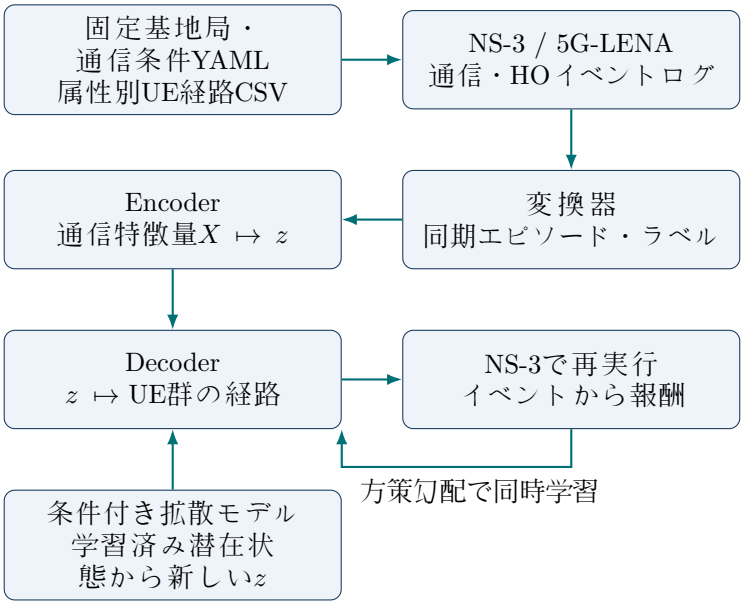
危険通信シナリオの潜在生成

EpisodicDT-small：現在の実装と学習の流れ

2026年10月23日版　ミーティング用説明資料

1. 研究目的と全体構成

通信状態の時系列から潜在状態を学習し、HOF（ハンドオーバー失敗）またはピンポンHOが起きるUE群の移動経路を生成する。生成した経路の危険性は、NS-3による再シミュレーションで確認する。



3つの主な構成要素

1. 変換器：シミュレーション結果を特徴量・欠損マスク・イベントラベルへ変換。
2. Encoder・Decoder：NS-3の報酬で同時学習し、危険な経路を生成。
3. 潜在状態生成器：学習済みEncoderの潜在状態を条件付き拡散モデルで学習。

現在は分類器も、元の通信系列・元経路を復元する再構成損失も使用しない。成功条件は「対象イベントがどれか1台に発生すること」であり、全UEのイベント一致ではない。

2. シミュレーション条件と学習データ

訓練用CSVから、イベントを付与した同期エピソードへ

項目	現在の条件
UE構成	車両18台・歩行者4台・静止2台、計24台
固定基地局	$(0, 0, 10)$、$(400, 0, 10)$ m。YAMLで固定
無線・伝搬	3.5 GHz、20 MHz、UMi、シャドウイング無効
送信電力	gNB 30 dBm、UE 23 dBm
HO制御	A3：ヒステリシス3 dB、TTT 256 ms
トラフィック	各UEの上下方向に200 byte、300 packet/s
記録周期	100 ms。古い測定値は欠損として扱う

入力CSVの列は次のとおり（単位は秒・m）。

```
timestamp,ue_id,location_x,location_y
```

車両・歩行者・静止UEを別CSVに保存し、点間は直線補間する。同じ座標を連続時刻に指定すると停止になる。

ラベルはNS-3のトレースをPythonで解釈して作る。

- HOF：`HandoverEndError`、プリアンブル不足、RACH試行上限、Leaving／Joining失敗のイベント。
- ピンポン：同じUEで成功した$A \to B$の後、2秒以内に$B \to A$が完了すること。HO開始だけでは陽性にしない。
- RLF：データ形式には項目があるが、検出検証が未完了のため現在の学習報酬には使用しない。

区分	同期エピソード	危険あり	既知の非危険
訓練	26	22	4
検証	9	7	2
評価	18	14	4

84実行条件のうち正常終了53条件を採用した既存データ。同一経路の派生・乱数違いは同じ区分に配置する。この集計は今回のNS-3修正前に作成したデータに基づく。

原ログは`training_dataset_next_screen/`、統合した学習データと設定は`training_dataset_next/`にある。学習時も原ログを参照するので両方を保持する。

3. Encoder：通信エピソードから潜在状態へ

UEごとの時間変化をTransformerで処理し、シナリオ全体を圧縮

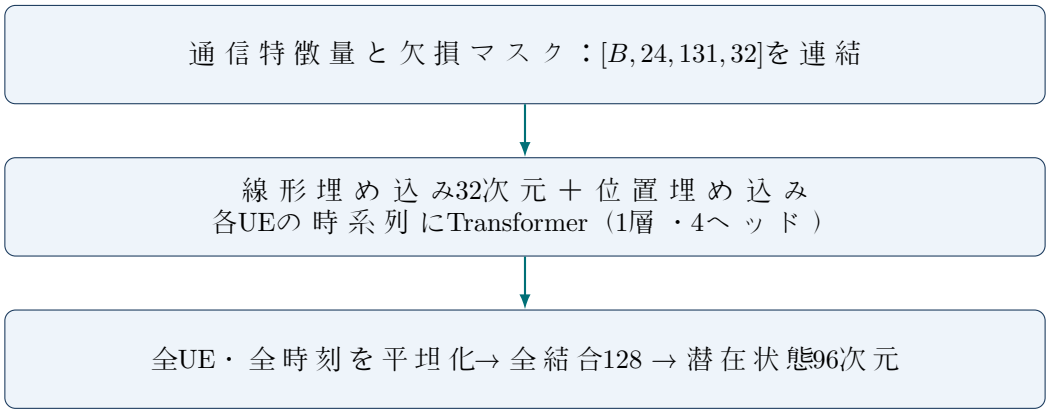
入力を$X \in \mathbb{R}^{N\times T\times F}$、観測マスクを$M \in \{0,1\}^{N\times T\times F}$ とする。現在は$N=24$、$T=131$、$F=32$。

特徴量	内容
共通11特徴	速度・速度成分、接続セルのRSRP・SINR、測定経過時間、接続セル距離、上下の提供トラフィック
セル別21特徴	最大3セル分。各セルのRSRP、経過時間、距離、相対位置3成分、接続中フラグ

実配置は2基地局だが、入力スキーマは最大3セル分を確保する。特徴量は訓練データから求めた統計で標準化し、検証・評価にも同じ統計を使用する。

$$
\begin{aligned}
\widetilde{X} &= [\mathrm{maskfill}(X, M, 0),\ M], \\
H_{u,t} &= W_{\mathrm{in}}\widetilde{X}_{u,t} + b_{\mathrm{in}} + P_t, \\
G_u &= \mathrm{Transformer}(H_u), \\
z &= f_\phi(X, M) = \mathrm{MLP}\big(\mathrm{Flatten}(G_1, \ldots, G_N)\big) \in \mathbb{R}^{96}.
\end{aligned}
$$

P_t は学習可能な時刻位置埋め込み。Transformerは各UEに共通で、UE間の情報は後段の全結合層で統合する。



131点は3秒のwarmupと10秒の対象区間・終端を含む入れ物である。通信特徴量を入れるのは対象区間の100点。warmupの30点と終端1点はマスクで欠損扱いにする。イベントラベル自体はEncoderへの入力ではない。

4. Decoder：潜在状態からUE群の経路へ

確率的な行動を生成し、速度・初期位置を制約した移動点列へ変換

Decoderの全結合層は96 → 128 → 1944。各UEについて、初期位置2成分・初期方位1成分と、26区間それぞれの旋回・速度・停止パラメータを生成する。

$$a \sim \pi_\theta(a \mid z) = \mathcal{N}(\mu_\theta(z),\, 0.35^2 I), \qquad D(a) \in \mathbb{R}^{24\times 27\times 3}.$$

$D(a)$ の末尾3成分は(t, x, y)。13秒間を0.5秒刻みの26区間・27点で表す。検証時は確率分布の平均$a = \mu_\theta(z)$ を使用する。

初期位置の制約

$$p_{u,0} = \ell + (h - \ell) \odot \sigma(a_u^{\text{pos}}), \quad x_0 \in [-100, 1100], \quad y_0 \in [-200, 200] \text{ m}.$$

速度・停止と経路の計算

$$\begin{aligned}
\vartheta_{u,k} &= a_u^{\text{heading}} + \sum_{j=1}^{k} a_{u,j}^{\text{turn}}, \\
v_{u,k} &= \big(v_u^{\min} + (v_u^{\max} - v_u^{\min})\sigma(a_{u,k}^{\text{speed}})\big)\mathbf{1}[a_{u,k}^{\text{stop}} < 0], \\
p_{u,k} &= p_{u,k-1} + 0.5\, v_{u,k}(\cos\vartheta_{u,k}, \sin\vartheta_{u,k}).
\end{aligned}$$

σ はシグモイド。停止を許さない属性では停止ゲートを使用しない。現在は全属性で停止を許可する。

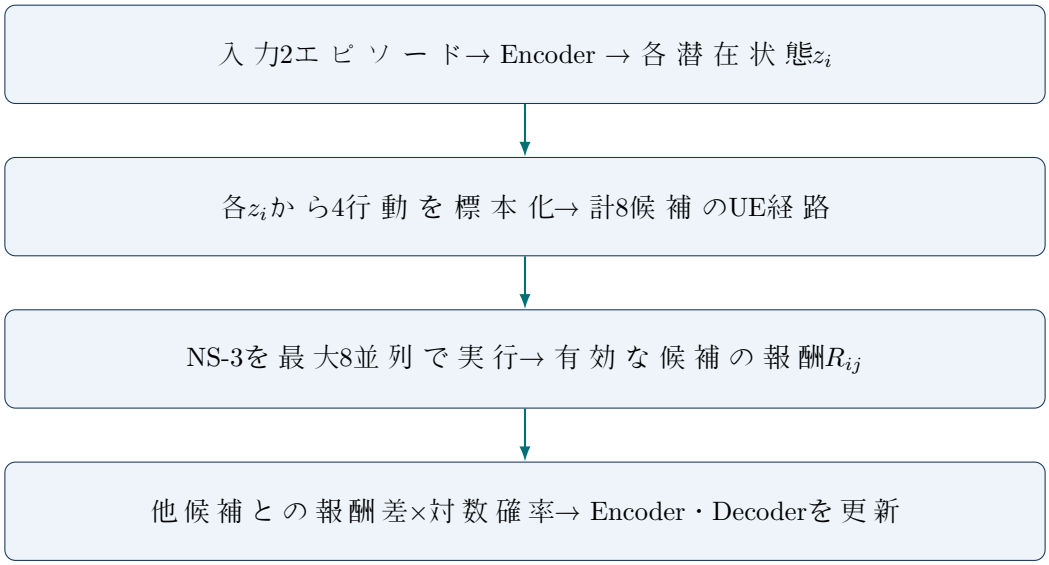
UE属性	移動中の速度	停止時
車両	1–65 m/s	0 m/s
歩行者	0.3–2 m/s	0 m/s
静止	0 m/s	0 m/s

出力は属性別の`car.csv`、`walker.csv`、`static.csv` と、UEごとの移動点配列を含む`routes.json`。元エピソードとUE数・属性・並び順は同じ。

速度と初期位置は変換式で制約するため、違反を罰する損失は不要。加速度・旋回角度、移動後の位置、道路との整合性、UE間衝突には制約を設けていない。現実性の保証はこの範囲に限られる。

5. Encoder・Decoderの同時学習

NS-3を微分せず、REINFORCEで生成分布を更新



$$R = \begin{cases} +1 & \exists u:\ \text{対象時間内にHOFまたはピンポンが確認された,} \\ -1 & \text{全UEで対象イベントがないと確認された.} \end{cases}$$

異常終了・判定不能は報酬−1にせず無効とする。同じ入力に対する有効候補集合をV_iとし、$|V_i| \geq 2$の入力だけを方策勾配に使う。

$$b_{ij} = \frac{1}{|V_i| - 1} \sum_{k \in V_i,\ k \neq j} R_{ik},$$

$$\mathcal{L}_{\mathrm{PG}} = -\frac{1}{\sum_i |V_i|} \sum_i \sum_{j \in V_i} \mathrm{stopgrad}(R_{ij} - b_{ij}) \log \pi_\theta(a_{ij} \mid f_\phi(X_i, M_i)),$$

$$\mathcal{L} = \mathcal{L}_{\mathrm{PG}} + 10^{-4}\,\mathrm{mean}(z^2).$$

使用しない静止UEの移動パラメータなどは対数確率の和から除く。AdamW、学習率10^{-4}、勾配ノルム上限1で更新する。十分な有効候補がなければ追加試行し、更新をスキップする場合もある。

同じ入力の有効候補が全て+1なら、$R_{ij} - b_{ij} = 0$となり報酬由来の勾配は0。成功率が上限に達した後も、正則化だけで更新が続く可能性がある。元経路への近さは学習目標に含めない。

6. 条件付き潜在拡散モデルの学習

Encoder・Decoderを固定し、潜在分布をノイズ除去で学ぶ

学習済みEncoderから訓練潜在状態z_iを抽出し、訓練集合の平均・標準偏差で正規化する。

$$h_i = (z_i - \mu_z)/s_z, \qquad s_z \geq 10^{-3}.$$

条件はUE番号を含めず、イベントごとに任意のUEで発生したかを集約する。

$$q_e = \bigvee_u (Y_{u,e} \wedge K_{u,e}), \qquad k_e = q_e \vee \bigwedge_u K_{u,e}, \qquad c = [q, k] \in \{0,1\}^6.$$

現在RLFのマスクは学習対象外。イベント条件は拡散モデルに入力するが、NS-3報酬は依然として「任意のUEのHOFまたはピンポン」である。

前向きのノイズ付加と学習損失

$$t \sim \mathrm{Uniform}\{0, \ldots, 99\}, \quad \epsilon \sim \mathcal{N}(0, I),$$

$$h_t = \sqrt{\bar{\alpha}_t}\, h_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon, \qquad \bar{\alpha}_t = \prod_{s=0}^{t} (1 - \beta_s),$$

$$\mathcal{L}_{\text{noise}} = \mathbb{E}\big[\|\epsilon - \epsilon_\psi(h_t, t, c)\|_2^2 / 96\big].$$

コサイン型のノイズスケジュールを使用する。予測器は潜在状態・時刻埋め込み32次元・条件を連結したMLP（隠れ128次元、2層）。AdamW、学習率10^{-3}、バッチ32で600回の最適化更新を行う。設定名は`epochs` だが、実装では1回につき1バッチの更新である。

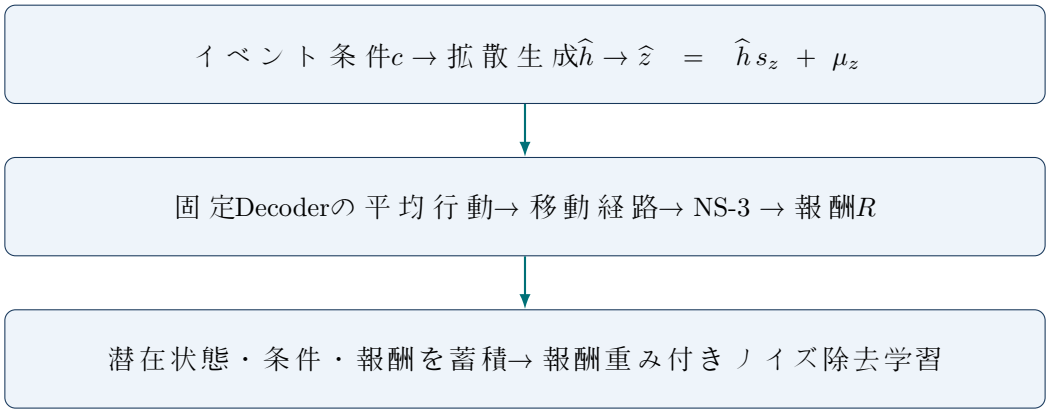
生成方法

- ノイズ開始：$h_{99} \sim \mathcal{N}(0, I)$から逆拡散する。
- 現在の既定値：条件が完全一致する訓練h_0を選び、$t = \mathrm{round}(0.15 \times 99) = 15$までノイズを加え、逆拡散する。
- 完全一致する訓練例がなければ、指定条件を変えずにノイズ開始へ切り替える。検証潜在状態を生成の出発点にはしない。

逆拡散でノイズを除去することと、元の通信エピソード・元経路を再構成することは別である。現在の実装はイベント指定の厳密一致を保証せず、再現性能はシミュレーションで確認する。

7. 拡散モデルへのNS-3フィードバック

危険イベントを確認した潜在状態を重視して追加学習



1ラウンドで24候補を生成・実行し、正常に評価できた潜在状態を蓄積する。5ラウンド、各ラウンド100回の追加最適化を行う。NS-3による候補評価は最大8並列。高速化設定では追加学習候補だけ危険確定時に終了する。

同じ条件cのリプレイ集合をG_cとして、重みを定める。

$$w_j = |G_c| \frac{\exp(R_j/\tau)}{\sum_{k \in G_c} \exp(R_k/\tau)}, \qquad \tau = 0.5.$$

$$\mathcal{L}_{\text{feedback}} = \frac{1}{B} \sum_{j \in \mathcal{B}} w_j \, \ell_{\text{noise}}(\hat{h}_j, c_j) + \lambda_{\text{anchor}} \frac{1}{B} \sum_{i \in \mathcal{T}} \ell_{\text{noise}}(h_i, c_i), \qquad \lambda_{\text{anchor}} = 1.$$

第1項は危険な生成例を相対的に重視する。第2項は元の訓練潜在分布からの過度な変化を抑える。更新対象は拡散モデルだけで、Encoder・Decoderは固定する。

モデルの選択と注意点

- 初期ノイズ除去学習では検証ノイズMSEが最小の状態を選ぶ。
- 追加学習では固定した検証乱数条件のNS-3報酬で最良状態を選ぶ。
- 同じ条件の全候補が同じ報酬なら$w_j = 1$であり、報酬による優劣は付かない。
- 拡散モデルの検証では現在、有効候補だけの平均を使う。不完全な検証の扱いは、同時学習側とまだ統一されていない。

発生UEが異なっても同じシナリオ条件として扱う。現在の検証9エピソードはすべて訓練集合に同じ条件がある。将来、未出の条件があればノイズ開始へ切り替える。旧144次元の拡散モデルは再学習が必要だが、Encoder・Decoderは再利用できる。

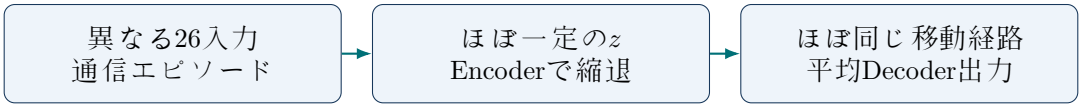
8. 今回の評価結果：経路の多様性を獲得できなかった

生成30候補がほぼ同一経路となり、研究目的を十分に達成できていない

評価対象：`evaluation_scenario_001`。30候補、生成seed 123、NS-3のrun 201・202・203。初期位置から終端まで、同じUE・同じ時刻の座標を比較した。

確認項目	実測結果
訓練入力の種類	26件すべて異なる
Encoder出力の次元別標準偏差の平均	約2.7×10^{-8}
生成30候補の候補間平均経路距離	約0.0022 m（2.2 mm）
有効な評価候補／無効候補	23候補／7候補
有効候補の危険イベント成功率	19/69実行＝約27.5%

経路距離は全候補対について、対応する24UE・27時刻の2次元ユークリッド距離を平均した値。潜在状態を保存済みDecoderで再変換して計測した。無効7候補は成功率の分母から除外しており、27.5%だけで全体性能を判断しない。



確認できた事実と、原因として考えられる仕組み

1. **潜在状態が既に縮退している。** 入力は異なるがEncoder出力はほぼ同じ。拡散モデルはその狭い分布を学ぶため、拡散だけで多様性を回復するのは難しい。
2. **成功報酬が飽和している。** 同時学習81更新中76更新が平均+1。同じ入力の全候補が成功すると方策勾配は0。多様性・入力情報の保持を直接促す損失はなく、潜在状態の大きさを抑える正則化は残る。
3. **生成時の経路変化が小さい。** 評価はDecoderの平均行動を使用し、学習時の行動ノイズは加えない。アンカー近傍からの拡散生成も変化を限定する。
4. **追加学習で多様な候補が優先されない。** 拡散の全5ラウンドで訓練平均報酬+1。同条件で報酬が同じなら重みは一様で、異なる経路を残す動機がない。

主な観測は「Encoderの表現縮退と、生成経路の実質的な同一化」。各設計要因が縮退をどの程度引き起こしたかは、比較実験で切り分ける必要がある。学習・検証報酬+1は、多様性や未知乱数条件への汎化を保証しなかった。

9. 改善案と次の比較実験

危険イベントを維持しながら、多様な潜在状態・経路を生成する

優先1：Encoderの縮退とDecoderの入力無視を防ぐ

潜在状態の次元別分散を維持する損失を候補とする。例えば、バッチ内分散について

$$\mathcal{L}_{\text{var}} = \frac{1}{d}\sum_{k=1}^{d} \max\left(0, \gamma - \sqrt{\text{Var}_i(z_{i,k}) + \epsilon}\right).$$

γは目標標準偏差、ϵは数値安定化項。現在の入力2件だけでは分散推定が不安定なため、補助損失にはより多くの訓練入力を使う。潜在ノルム正則化の重みも比較する。

分散だけを大きくしても経路が変わらなければ不十分なので、異なるzに対するDecoder経路差も測定し、同時に改善する。元経路に似せる再構成を必須にはしない。

優先2：危険な経路同士の多様性を学習目標に加える

NS-3で危険を確認した経路を蓄積し、既存の成功経路から十分に異なる候補を評価する。初期位置の差だけでなく、初期位置を揃えた軌跡形状、訪問セル、HO発生時刻などを分けて測る。単にノイズを大きくして危険性を失う解を避ける。

優先3：生成時のランダム性を比較する

平均行動と確率的なDecoder行動、アンカー開始とノイズ開始、拡散のノイズ強度を同じ条件で比較する。行動ノイズで経路が変わることと、多様な危険経路を学べたことは区別する。

比較する段階	主な確認項目
現状のモデル	成功率、無効率、経路差、潜在分散の基準値
潜在分散制約を追加	zの分散とDecoder出力の違いが共に増えるか
成功経路の多様性を追加	危険性を保って異なる成功経路が増えるか
生成時の乱数・強度を変更	多様性と成功率の両方を維持できるか

モデル選択にも危険成功率と多様性を併用し、最終評価は選択に使わないデータ・乱数条件で行う。HOF・ピンポン別の成功率と無効率を併記する。拡散モデルの不完全な検証の扱いも統一する。

これらは改善案であり、まだ実装・効果検証していない。次はEncoder・Decoderの学習を見直し、その潜在分布で拡散モデルを再学習する。8並列と訓練候補の早期終了は計算時間短縮に使い、性能評価は全期間を実行する。

10. 実行手順と保存先

現在の設定を使い、モデルとシミュレータの由来を保持する

すべてプロジェクト直下・episodicdt 環境で実行する。学習用設定は同時学習用と拡散モデル用の2つに統一した。

A. 高速化版Encoder・Decoderを再開

```
OMP_NUM_THREADS=1 python -m src.train.train_mobility \
 --config data/processed/training_dataset_next/training_fast.yaml \
 --resume
```

B. 高速化版を初めて開始（通常版の重みを引き継ぐ）

```
OMP_NUM_THREADS=1 python -m src.train.train_mobility \
 --config data/processed/training_dataset_next/training_fast.yaml \
 --initialize-from \
 data/processed/training_dataset_next/mobility_inflight_fixed/latest.pt
```

通常版の学習を停止してから起動する。新規保存先はmobility_fast/。optimizerを初期化し初期検証をやり直す。開始済みの高速化版は同じ設定で--resumeを使う。

C. 通常版の学習済みモデルから拡散モデルを学習

```
OMP_NUM_THREADS=1 python -m src.train.train_diffusion \
 --config data/processed/training_dataset_next/training_diffusion_scenario.yaml \
 --checkpoint \
 data/processed/training_dataset_next/mobility_inflight_fixed/mobility.pt
```

新しく学習したモデルを使う場合も拡散用設定を使い、モデルのみmobility_fast/mobility.ptに変更する。拡散学習の検証はどちらも全期間実行する。

保存先（データセット直下）	内容
episodes/	訓練・検証・評価のNPZ
mobility_inflight_fixed/	通常版のモデル、最新再開状態、履歴
mobility_fast/	高速化版のモデル・履歴・実行結果
diffusion_scenario/	シナリオ条件の拡散モデル・追加学習記録
diffusion_fast/	高速化版からの拡散モデル・記録

モデル本体：src/models/mobility.py、latent_diffusion.py。

学習：src/train/train_mobility.py、train_diffusion.py。

実行・報酬：src/simulation/runner.py。

詳細はREADME、docs/training_speed.md、

docs/diffusion_anchor_fix.mdを参照。